



Unidoc Finder

Motor de Pesquisa de Dissertações

David Sousa
Nuno Patrocínio

Orientador: Nuno Leite

Relatório do projeto realizado no âmbito de Projeto e Seminário
Licenciatura em Engenharia Informática e de Computadores

11 de julho de 2026

INSTITUTO SUPERIOR DE ENGENHARIA DE LISBOA

Unidoc Finder

Motor de Pesquisa de Dissertações

David Sousa, n.º48190, e-mail: a48190@alunos.isel.pt

Nuno Patrocínio, n.º49442, e-mail: a49442@alunos.isel.pt

Orientador: Nuno Leite, e-mail: nuno.leite@isel.pt

Relatório do projeto realizado no âmbito de Projeto e Seminário
Licenciatura em Engenharia Informática e de Computadores

11 de julho de 2026

Resumo

O presente relatório descreve o desenvolvimento do *Unidoc Finder*, uma plataforma web especializada na pesquisa de teses e dissertações produzidas por instituições de ensino superior portuguesas. O projeto surge da necessidade de centralizar o acesso a trabalhos académicos que se encontram distribuídos por diferentes repositórios institucionais, tornando a pesquisa mais simples, rápida e organizada.

A solução proposta agrega metadados recolhidos automaticamente através de um *web crawler*, sem armazenar diretamente os documentos originais. Para cada trabalho são indexadas informações como título, autor, resumo, ano de publicação, universidade e ligação para o repositório de origem. A arquitetura do sistema é composta por um frontend desenvolvido em React e TypeScript, uma *Application Programming Interface* (API) em Kotlin com Spring Boot, uma base de dados PostgreSQL para armazenamento persistente e o Elasticsearch como indexador dos dados.

O sistema permite ao utilizador realizar pesquisas por palavras-chave, consultar resultados ordenados por relevância, aplicar filtros e aceder diretamente às páginas originais dos documentos. Toda a aplicação é containerizada com Docker, facilitando a execução e integração dos diferentes componentes. Desta forma, o *Unidoc Finder* pretende contribuir para melhorar a visibilidade, reutilização e acessibilidade da produção científica nacional.

Palavras-chave: Elasticsearch; metadados académicos; repositórios institucionais; teses e dissertações; Unidoc Finder; web crawler.

Abstract

This report describes the development of *Unidoc Finder*, a web platform specialized in the search of theses and dissertations produced by Portuguese higher education institutions. The project arises from the need to centralize access to academic works that are distributed across different institutional repositories, making the search process simpler, faster, and more organized.

The proposed solution aggregates metadata automatically collected through a *web crawler*, without directly storing the original documents. For each work, information such as title, author, abstract, publication year, university, and link to the original repository is indexed. The system architecture is composed of a frontend developed in React and TypeScript, an API in Kotlin with Spring Boot, a PostgreSQL database for persistent storage, and Elasticsearch as the text search engine.

The system allows users to perform keyword searches, consult results ordered by relevance, apply filters, and directly access the original pages of the documents. The entire application is containerized with Docker, facilitating the execution and integration of the different components. In this way, *Unidoc Finder* aims to contribute to improving the visibility, reuse, and accessibility of national scientific production.

Keywords: academic metadata; Elasticsearch; institutional repositories; theses and dissertations; Unidoc Finder; web crawler.

Responsabilidade Sobre o Uso de IA Generativa

Durante o desenvolvimento do presente trabalho e a elaboração do respetivo relatório, foram utilizadas ferramentas de Inteligência Artificial Generativa como apoio em determinadas tarefas:

- esclarecer conceitos relacionados com o tema do trabalho;
- sugerir abordagens para a resolução de determinados problemas;
- auxiliar na análise e revisão de código;
- apoiar a escrita e a formatação de conteúdos em L^AT_EX;
- melhorar a clareza da escrita e a gramática do relatório;
- auxiliar a escrita de comentários do código fonte.

As ferramentas de Inteligência Artificial Generativa não foram utilizadas para substituir o trabalho, a análise crítica, a tomada de decisões ou a validação dos resultados por parte dos autores. Todas as respostas, sugestões e conteúdos gerados foram analisados, verificados e, quando necessário, corrigidos ou adaptados antes da sua aplicação no trabalho ou inclusão no relatório.

Os autores assumem integralmente a responsabilidade pelo trabalho desenvolvido e pelo conteúdo final apresentado, incluindo a metodologia adotada, o código produzido, a exatidão das informações, a seleção e interpretação das fontes, os resultados obtidos, as conclusões apresentadas e eventuais erros ou omissões.

As ferramentas de Inteligência Artificial Generativa foram utilizadas exclusivamente como instrumentos de apoio, não sendo consideradas autoras do trabalho, fontes bibliográficas ou autoridades científicas.

Índice

1	Introdução	1
1.1	Motivação	1
1.2	Objetivo do Projeto	1
1.3	Aplicações similares: Google Scholar	2
1.4	Organização do Relatório	3
2	Formulação do Problema	5
2.1	Requisitos Funcionais	5
2.2	Arquitetura e Tecnologias Utilizadas	5
2.2.1	Aplicação Web (Frontend)	5
2.2.2	Backend	6
2.2.3	Motor de Pesquisa	6
2.2.4	Base de Dados	6
2.2.5	Web Crawler	6
2.2.6	Infraestrutura	6
2.2.7	Diagrama	6
2.3	Desafios a Enfrentar	7
2.3.1	Extração de Dados	7
2.3.2	Relevância das Pesquisas	7
2.3.3	Velocidade de Pesquisa	7
2.3.4	Diferenças dos Filtros	8
3	Implementação	9
3.1	Frontend	9
3.1.1	Estrutura da aplicação	9
3.1.2	Componente principal e estado da interface	10
3.1.3	Comunicação com a API	10
3.1.4	Modelo de dados e mapeamento	10
3.1.5	Componentes da interface	10
3.1.6	Filtros e paginação	11
3.1.7	Estilização e responsividade	11
3.1.8	Execução em desenvolvimento e Docker	11
3.1.9	Limitações da implementação atual	12
3.2	API	12
3.2.1	Arquitetura da Aplicação	12
3.2.2	Tecnologias Utilizadas	12
3.2.3	Modelo de Dados	13
3.2.4	Endpoints Disponibilizados	13
3.2.5	Fluxo de Pesquisa	13
3.2.6	Comunicação com PostgreSQL e Elasticsearch	14
3.2.7	Containerização	14
3.2.8	Testes	14
3.3	Elasticsearch	14
3.3.1	Motivação para a utilização do Elasticsearch	15
3.3.2	Modelo de Indexação	16
3.3.3	Processo de Indexação	16

3.3.4	Funcionamento das Pesquisas	17
3.3.5	Vantagens para o Projeto	17
3.4	Base de Dados	17
3.4.1	Modelo de Dados	18
3.4.2	Estrutura das Tabelas	18
3.4.3	Fluxo de Dados	18
3.5	Web Crawler	18
3.5.1	Repositórios configurados	19
3.5.2	Recolha HTTP	19
3.5.3	Metadados extraídos	19
3.5.4	Filtragem de teses e dissertações	20
3.5.5	Deduplicação	20
3.5.6	Envio dos dados para a API	21
3.5.7	Testes	21
3.5.8	Limitações da implementação atual	21
4	Conclusão	23
4.1	Tarefas Cumpridas	23
4.2	Desafios	23
4.3	Trabalho Futuro	24
	Referências	25

1 Introdução

Este capítulo apresenta o projeto e explica a organização deste relatório.

1.1 Motivação

A motivação para este projeto surge da dificuldade sentida por estudantes, investigadores e outros interessados em encontrar teses académicas de forma centralizada e eficiente. Atualmente, muitas universidades disponibilizam a sua produção científica em repositórios próprios, mas estes encontram-se, na maioria dos casos, separados entre si e sem uma integração comum que permita uma pesquisa abrangente.

Esta fragmentação obriga os utilizadores a pesquisar manualmente em cada repositório universitário, tornando o processo demorado, repetitivo e pouco prático. Além disso, quando se recorre a motores de pesquisa generalistas, os resultados apresentados nem sempre são os mais relevantes ou específicos para o contexto académico, podendo dificultar o acesso aos documentos.

Assim, torna-se relevante desenvolver uma solução que facilite a descoberta e consulta de trabalhos académicos produzidos em instituições de ensino superior. Ao melhorar o acesso a este conhecimento, pretende-se contribuir para a sua maior visibilidade, reutilização e valorização no contexto académico e científico.

1.2 Objetivo do Projeto

O principal objetivo deste projeto é desenvolver uma plataforma especializada na pesquisa de teses e dissertações de instituições de ensino superior em Portugal. Esta plataforma pretende agregar informação proveniente de diferentes repositórios institucionais, permitindo ao utilizador encontrar trabalhos académicos de forma mais simples, rápida e organizada.

Para suportar o seu funcionamento, o sistema será composto por um motor de pesquisa e um *web crawler*[1] responsável pela recolha automática de metadados presentes nos repositórios públicos das universidades. Em vez de armazenar diretamente os documentos, a plataforma irá indexar apenas os metadados relevantes e disponibilizar ligações que redirecionam o utilizador para o repositório original onde o trabalho se encontra disponível.

Com base nesta arquitetura, o projeto pretende atingir os seguintes objetivos:

- **Centralizar a pesquisa académica**, permitindo ao utilizador realizar uma única pesquisa que agregue resultados de vários repositórios universitários.
- **Indexar e organizar metadados de dissertações**, incluindo título, autor, resumo, ano de publicação e ligação para o repositório original.
- **Melhorar a relevância dos resultados de pesquisa**, focando-se especificamente em trabalhos produzidos por instituições portuguesas e evitando resultados pouco relevantes.
- **Automatizar a recolha de informação**, através de um *web crawler* capaz de obter periodicamente novos dados dos repositórios institucionais.

Desta forma, o projeto pretende contribuir para facilitar o acesso à produção científica nacional e aumentar a visibilidade das dissertações desenvolvidas nas instituições de ensino superior portuguesas.

De forma geral, a plataforma é composta por uma interface web, através da qual o utilizador realiza pesquisas, por uma componente de pesquisa responsável por consultar os metadados indexados, e por um *web crawler* encarregado de recolher informação pública a partir dos repositórios universitários. A figura 1 apresenta uma visão simplificada dos principais atores e componentes do sistema.




Figura 1: Arquitetura geral da plataforma proposta.

1.3 Aplicações similares: Google Scholar

Nos últimos anos, a disponibilização digital de trabalhos académicos tem crescido significativamente, impulsionada pela adoção de repositórios institucionais por universidades e centros de investigação. Estes repositórios permitem armazenar, preservar e disponibilizar teses, dissertações, artigos científicos e outros documentos produzidos no contexto académico.

Em Portugal, a maioria das instituições de ensino superior disponibiliza os seus trabalhos académicos através de plataformas próprias, muitas delas baseadas em soluções como o DSpace[9]. Embora estes sistemas permitam o acesso aberto ao conhecimento produzido pelas instituições, a informação encontra-se frequentemente distribuída por múltiplos repositórios independentes, dificultando a realização de pesquisas abrangentes.

Para ultrapassar esta limitação, surgiram plataformas agregadoras que recolhem informação de diferentes fontes e disponibilizam mecanismos de pesquisa centralizados. Exemplos internacionais incluem o Google Scholar, que permitem pesquisar milhões de

publicações científicas provenientes de diversas instituições e repositórios. No entanto, estas plataformas têm um âmbito muito amplo e incluem vários tipos de documentos científicos, nem sempre oferecendo uma experiência especializada para a pesquisa de dissertações acadêmicas.

Relativamente aos mecanismos de pesquisa, soluções modernas recorrem frequentemente a motores especializados como o Elasticsearch[?], capazes de indexar grandes volumes de informação e executar pesquisas em tempo reduzido. Estas ferramentas disponibilizam funcionalidades avançadas, incluindo pesquisa textual, relevância baseada em pontuação, filtragem por atributos e suporte para consultas complexas.

O nosso projeto enquadra-se neste contexto, procurando criar uma plataforma focada especificamente na pesquisa de dissertações e teses produzidas por instituições portuguesas. A solução diferencia-se por concentrar a pesquisa num domínio específico, recorrendo à recolha automática de metadados dos repositórios universitários e à indexação desses dados num motor de pesquisa otimizado, permitindo aos utilizadores encontrar trabalhos académicos de forma mais simples, rápida e centralizada.

1.4 Organização do Relatório

O presente relatório encontra-se organizado em cinco capítulos principais.

O primeiro corresponde à **Formulação do Problema**, onde são descritos os requisitos funcionais da plataforma, a arquitetura proposta, as tecnologias utilizadas, o diagrama geral do sistema e os principais desafios previstos, como a extração de dados, a relevância das pesquisas, a velocidade de pesquisa e as diferenças entre filtros disponibilizados pelos repositórios.

O segundo corresponde à **Implementação**, onde é explicado o desenvolvimento dos principais componentes do sistema: o frontend, a API, o Elasticsearch, a base de dados e o web crawler. Neste capítulo são também abordadas a estrutura da aplicação, a comunicação entre componentes, o modelo de dados, o processo de indexação, a recolha de metadados e as limitações da implementação atual.

Por fim, o terceiro corresponde à **Conclusão**, onde são apresentados o trabalho realizado, as tarefas cumpridas, os desafios encontrados ao longo do desenvolvimento e possíveis melhorias a implementar no futuro.

2 Formulação do Problema

Este capítulo apresenta os requisitos funcionais do projeto, a sua arquitetura e tecnologias a utilizar, o diagrama de blocos e os problemas a enfrentar.

2.1 Requisitos Funcionais

Com base nos objetivos definidos, o sistema deverá cumprir um conjunto de requisitos funcionais que garantam a sua utilidade para os utilizadores finais. Estes requisitos descrevem as principais funcionalidades que a plataforma deverá disponibilizar e incluem:

- **Pesquisar teses e dissertações de faculdades portuguesas** – o sistema deverá permitir ao utilizador realizar pesquisas por palavras-chave, apresentando resultados relacionados com teses e dissertações provenientes de instituições de ensino superior em Portugal.
- **Disponibilizar ligações (links) diretos para os repositórios originais** – cada resultado apresentado deverá incluir uma ligação para o repositório institucional original onde a tese ou dissertação se encontra disponível, garantindo o acesso à fonte oficial do documento.
- **Suportar filtros de pesquisa** – o sistema deverá permitir ao utilizador refinar os resultados através de filtros como ano de publicação, universidade, faculdade ou autor, facilitando a localização de trabalhos académicos específicos.

2.2 Arquitetura e Tecnologias Utilizadas

A arquitetura do sistema será composta pelos seguintes componentes principais:

- Aplicação Web (Frontend)
- Backend
- Motor de Pesquisa
- Base de Dados
- Web Crawler
- Infraestrutura

Estes são descritos nas subsecções seguintes.

2.2.1 Aplicação Web (Frontend)

A interface do utilizador será desenvolvida utilizando *React*[2], permitindo criar uma aplicação web responsiva e fácil de utilizar. Através desta interface, os utilizadores poderão pesquisar todo o tipo de documentos com foco em dissertações, visualizar resultados e aceder diretamente às páginas originais dos repositórios.

2.2.2 Backend

O *backend* será desenvolvido em *Kotlin*[3] utilizando o framework *Spring Boot*[4], sendo responsável pela lógica da aplicação, processamento das pesquisas e comunicação entre os diferentes componentes do sistema. O *backend* disponibilizará também uma *REST API* que permitirá ao *frontend* realizar consultas ao motor de pesquisa.

2.2.3 Motor de Pesquisa

Para a indexação e pesquisa da informação será utilizado o *Elasticsearch*[6][7], uma plataforma de pesquisa distribuída que permite realizar consultas rápidas e eficientes sobre grandes volumes de dados.

2.2.4 Base de Dados

Para guardar dados será criada uma base de dados em *postgres*[5], a qual será acessada pelo componente de pesquisa para obter os resultados de pesquisa pretendidos.

2.2.5 Web Crawler

Será desenvolvido um *web crawler* responsável por recolher automaticamente os meta dados dos documentos presentes nos repositórios institucionais.

2.2.6 Infraestrutura

Toda a aplicação está *containerizada* utilizando *Docker*, permitindo executar os diferentes componentes do sistema em ambientes isolados e facilitando o processo de *deploy* e manutenção da plataforma.

2.2.7 Diagrama

A figura 2 representa a arquitetura do sistema.




Figura 2: Arquitetura do sistema: interação entre utilizador, interface web, backend, bases de dados, crawler e os repositórios universitários.

2.3 Desafios a Enfrentar

O desenvolvimento deste projeto apresenta alguns desafios que serão elencados nas secções seguintes.

2.3.1 Extração de Dados

Os diferentes repositórios institucionais podem apresentar estruturas e formatos diferentes, o que pode dificultar a criação de um *crawler* capaz de extrair meta dados de forma consistente.

2.3.2 Relevância das Pesquisas

Configurar corretamente o sistema de indexação e os mecanismos de pesquisa será fundamental para garantir que os resultados apresentados aos utilizadores são relevantes e úteis.

2.3.3 Velocidade de Pesquisa

Garantir uma velocidade de pesquisa eficiente será um dos desafios do projeto, uma vez que o tempo de resposta pode ser influenciado por fatores como o volume de dados indexados e a complexidade das consultas realizadas.

2.3.4 Diferenças dos Filtros

Em cada repositório existem filtros diferentes. Será necessário analisar e filtrar a informação de cada repositório para identificar quais os filtros disponíveis e quais são comuns entre eles, de forma a integrá-los no motor de pesquisa.

Superar estes desafios será essencial para desenvolver uma plataforma eficiente e fiável que permita melhorar o acesso à produção académica das instituições de ensino superior portuguesas.

3 Implementação

Esta secção apresenta a implementação do projeto.

3.1 Frontend

O *frontend* foi implementado como uma aplicação web em *React* e *TypeScript*, utilizando *Vite* como ferramenta de desenvolvimento e empacotamento. Este componente é responsável pela interação direta com o utilizador, permitindo introduzir termos de pesquisa, selecionar o tipo de documento, aplicar filtros e visualizar os resultados obtidos através da *Application Programming Interface* (API) do sistema.

A aplicação segue uma arquitetura de componentes. O ponto de entrada encontra-se em `src/main.tsx`, onde o componente principal **App** é montado no elemento **root** da página HTML. A partir desse componente são agregadas as principais áreas da interface: cabeçalho, barra de pesquisa, painel lateral de filtros e lista de resultados.

3.1.1 Estrutura da aplicação

O código-fonte encontra-se organizado por responsabilidade, separando a interface visual, a comunicação com a API, os tipos de dados e a transformação dos objetos recebidos do backend. A tabela 1 apresenta os principais ficheiros e diretórios da implementação.

Tabela 1: Organização principal do frontend.

Ficheiro / Diretório	Responsabilidade
<code>src/App.tsx</code>	Componente principal da aplicação. Mantém o estado da pesquisa, filtros, tipo de documento selecionado e página atual.
<code>src/api/httpClient.ts</code>	Cliente HTTP genérico usado para comunicar com a API através de pedidos <code>fetch</code> . Também trata erros de resposta.
<code>src/api/searchApi.ts</code>	Função específica para pesquisar teses através do endpoint <code>/api/search</code> .
<code>src/hooks/useThesisSearch.ts</code>	<i>Hook</i> responsável por executar a pesquisa, controlar o estado de carregamento e guardar os resultados recebidos.
<code>src/mappers/thesisMapper.ts</code>	Conversão dos objetos recebidos da API para o modelo interno usado pelos componentes visuais.
<code>src/types</code>	Definição dos tipos <code>ThesisApiDto</code> , <code>UniversityApiDto</code> , <code>DocumentRecord</code> , <code>SearchFilters</code> , <code>OptionItem</code> e <code>FilterOptions</code> .
<code>src/components</code>	Componentes reutilizáveis da interface, como barra de pesquisa, filtros, cartões de resultado e paginação.
<code>src/main/docker</code>	Ficheiros de suporte para execução do frontend em Docker durante o desenvolvimento.

Esta separação facilita a manutenção do código, uma vez que alterações na interface, no formato dos dados ou na comunicação com a API podem ser feitas em zonas bem delimitadas da aplicação.

3.1.2 Componente principal e estado da interface

O componente `App` centraliza o estado necessário para controlar a pesquisa. A aplicação guarda o tipo de documento selecionado, o texto escrito pelo utilizador, o termo de pesquisa submetido, os filtros ativos e a página atual. Foi definida uma constante `PAGE_SIZE` com o valor 10, fazendo com que cada pedido solicite, no máximo, dez resultados por página.

A distinção entre `queryInput` e `submittedQuery` permite que o utilizador escreva livremente na barra de pesquisa sem executar pedidos à API a cada alteração do campo. A pesquisa só é enviada quando o formulário é submetido. Nesse momento, o termo escrito passa para `submittedQuery` e a paginação volta à primeira página.

3.1.3 Comunicação com a API

A comunicação com o backend está concentrada na pasta `src/api`. O ficheiro `httpClient.ts` define a função genérica `apiRequest`, que acrescenta o prefixo `/api` ao caminho recebido, envia os cabeçalhos necessários e interpreta a resposta de acordo com o respetivo tipo de conteúdo. Quando a resposta HTTP indica erro, é lançada uma exceção `ApiError`, guardando o código de estado e o conteúdo devolvido pelo servidor.

A pesquisa de documentos é feita no ficheiro `searchApi.ts`, através da função `searchThesis`. Esta função constrói os parâmetros `query`, `page` e `size` com `URLSearchParams` e executa um pedido para o endpoint:

```
/api/search?query=<termo>&page=<pagina>&size=<tamanho>
```

O *hook* `useThesisSearch` encapsula esta chamada. Quando existe um termo de pesquisa válido, o *hook* ativa o estado de carregamento, chama a API, converte os resultados recebidos com `mapThesisToDocument` e disponibiliza os documentos ao componente principal. Caso ocorra uma falha, a mensagem de erro é guardada e apresentada pela lista de resultados.

3.1.4 Modelo de dados e mapeamento

O frontend distingue entre o formato recebido do backend e o formato usado internamente pela interface. A API devolve objetos do tipo `ThesisApiDto`, contendo o identificador, título, resumo, ano, URL do documento e informação da universidade. Para apresentação na interface, estes objetos são transformados em `DocumentRecord`.

3.1.5 Componentes da interface

A interface foi dividida em componentes reutilizáveis, cada um com uma responsabilidade específica:

- **Header:** apresenta o nome da aplicação, *Unidoc Finder*;
- **SearchBar:** contém a seleção do tipo de documento, o campo de pesquisa e o botão de submissão;
- **FilterSidebar:** apresenta os filtros por universidade, categoria, área e intervalo temporal;

- **FilterSection**: componente auxiliar usado para organizar visualmente cada grupo de filtros;
- **ResultsList**: apresenta os estados de carregamento, erro, ausência de resultados e a lista de documentos encontrados;
- **DocumentCard**: mostra cada resultado individual, incluindo ano, título, resumo, etiquetas, tipo de documento e universidade;
- **TagPill**: representa etiquetas visuais, sendo também usado para remover áreas selecionadas nos filtros;
- **UniversityBrand**: apresenta o nome da universidade associada ao documento.

Cada resultado apresentado inclui uma ligação externa para o URL original do documento. A ligação é aberta num novo separador, permitindo ao utilizador consultar o registo no repositório institucional sem perder o contexto da pesquisa na plataforma.

3.1.6 Filtros e paginação

O painel lateral permite refinar os resultados de acordo com vários critérios. O filtro de universidade é uma lista com todas as universidades disponíveis. O filtro de tipo permite seleccionar o tipo de documento. O filtro de autor permite escrever o nome do autor pretendido. O filtro de área permite executar uma pesquisa nas etiquetas de área. O filtro de ano permite escolher o ano do documento.

A paginação é controlada no componente **ResultsList**. O utilizador pode avançar ou recuar entre páginas através dos botões **Seguinte** e **Anterior**. O botão de página anterior fica desativado na primeira página, enquanto o botão de página seguinte depende da existência de uma página aparentemente completa, isto é, quando a quantidade de documentos recebidos é igual ao valor de **PAGE_SIZE**.

3.1.7 Estilização e responsividade

A estilização foi feita com CSS. O ficheiro **src/styles.css** define a estrutura geral da página, incluindo o fundo em gradiente, o espaçamento da aplicação e a grelha principal com duas colunas: uma para os filtros e outra para os resultados. Cada componente possui ainda o seu próprio ficheiro **.module.css**, o que reduz conflitos de estilos e mantém a apresentação visual associada ao respetivo componente.

A interface foi preparada para diferentes tamanhos de ecrã. Em ecrãs largos, os filtros surgem numa coluna lateral e os resultados ocupam a área principal. Em ecrãs mais pequenos, a grelha passa para uma única coluna, colocando os filtros acima dos resultados. A barra de pesquisa e os cartões de documentos também possuem regras específicas para se adaptarem a larguras reduzidas.

3.1.8 Execução em desenvolvimento e Docker

A execução em Docker é suportada pelo ficheiro **Dockerfile.dev**, baseado na imagem **node:24.14.0-alpine**. O contentor instala as dependências com **npm install**, expõe a porta 5173 e executa o servidor de desenvolvimento com **npm run dev**. O ficheiro **docker-compose.yml** define o serviço **unidoc-frontend**, usando esse **Dockerfile** e atribuindo ao contentor o nome **unidoc-frontend**.

3.1.9 Limitações da implementação atual

A paginação baseia-se numa heurística simples: assume-se que existe uma próxima página quando o número de resultados recebidos é igual ao tamanho máximo da página. Uma alternativa mais completa seria a API devolver também o número total de resultados ou um indicador explícito de existência de próxima página.

3.2 API

A API constitui o elemento central da arquitetura do sistema, sendo responsável pela comunicação entre a interface web, a base de dados PostgreSQL e o motor de pesquisa Elasticsearch. Este componente foi desenvolvido em *Kotlin* utilizando o framework *Spring Boot*, disponibilizando um conjunto de endpoints REST que permitem efetuar pesquisas e gerir os dados armazenados na plataforma.

A utilização de uma API dedicada permite desacoplar o frontend dos mecanismos internos de armazenamento e pesquisa, facilitando a manutenção, evolução e escalabilidade da aplicação.

3.2.1 Arquitetura da Aplicação

O backend segue uma arquitetura em camadas, separando as responsabilidades de acesso aos dados, lógica de negócio e exposição dos serviços.

A estrutura principal da aplicação é composta pelos seguintes componentes:

- **Controllers:** recebem os pedidos HTTP provenientes do frontend e devolvem as respetivas respostas.
- **Services:** implementam a lógica de negócio da aplicação, coordenando o acesso às bases de dados e ao Elasticsearch.
- **Repositories:** responsáveis pela comunicação com o PostgreSQL e com o Elasticsearch.
- **Entities:** representam os dados armazenados na base de dados relacional.
- **DTOs (Data Transfer Objects):** utilizados para transportar informação entre o backend e o frontend de forma controlada.

Esta organização contribui para uma melhor separação de responsabilidades e facilita a manutenção do código à medida que o projeto evolui.

3.2.2 Tecnologias Utilizadas

A API foi desenvolvida recorrendo às seguintes tecnologias:

- Kotlin;
- Spring Boot;
- Spring Web MVC;
- Spring Data JPA;

- Spring Data Elasticsearch;
- PostgreSQL;
- Docker.

O Spring Boot foi escolhido devido à sua integração com o ecossistema Spring, simplificando a criação de APIs REST e a ligação a bases de dados relacionais e motores de pesquisa.

3.2.3 Modelo de Dados

A API trabalha essencialmente com duas entidades principais:

- **University:** representa uma instituição de ensino superior e contém informação como o nome da universidade e o endereço do respetivo repositório.
- **Thesis:** representa uma tese ou dissertação indexada pelo sistema, contendo o título, resumo, ano de publicação, URL do documento e a universidade associada.

A relação existente entre estas entidades é do tipo um-para-muitos, uma vez que uma universidade pode possuir várias dissertações.

3.2.4 Endpoints Disponibilizados

Atualmente, a API disponibiliza um conjunto de endpoints para gestão e pesquisa de dados.

Método	Endpoint	Descrição
GET	/api/universities	Obtém as universidades registadas
POST	/api/universities	Regista uma universidade
POST	/api/thesis	Regista uma dissertação
GET	/api/thesis/exists	Verifica a existência de teses
GET	/api/search	Pesquisa dissertações
POST	/api/search/sync	Sincroniza o elastic

Tabela 2: Principais endpoints disponibilizados pela API.

Todos os pedidos e respostas são efetuados utilizando o formato JSON.

3.2.5 Fluxo de Pesquisa

Quando um utilizador realiza uma pesquisa através da interface web, o processo executado pela API segue os seguintes passos:

1. O frontend envia um pedido HTTP para o endpoint de pesquisa.
2. O controller recebe o pedido e valida os parâmetros recebidos.
3. O serviço de pesquisa executa uma consulta ao Elasticsearch.
4. O Elasticsearch devolve os documentos mais relevantes para o termo pesquisado.

5. Os resultados são convertidos para DTOs de resposta.
6. A API devolve os resultados ao frontend em formato JSON.

Este mecanismo permite obter tempos de resposta reduzidos mesmo quando o volume de documentos indexados aumenta significativamente.

3.2.6 Comunicação com PostgreSQL e Elasticsearch

A API utiliza simultaneamente duas tecnologias de armazenamento com objetivos distintos.

O PostgreSQL é responsável pelo armazenamento persistente dos dados da aplicação, garantindo consistência e integridade relacional.

O Elasticsearch é utilizado exclusivamente para pesquisa e indexação de documentos, permitindo efetuar consultas textuais rápidas e ordenar os resultados por relevância.

Esta abordagem combina as vantagens de uma base de dados relacional com as capacidades avançadas de um motor de pesquisa especializado.

3.2.7 Containerização

A API é executada dentro de um contentor Docker, permitindo uma configuração consistente entre ambientes de desenvolvimento e produção.

A utilização de Docker simplifica a distribuição da aplicação e facilita a integração com os restantes componentes do sistema, nomeadamente o PostgreSQL, o Elasticsearch e o frontend React.

3.2.8 Testes

Ao longo do desenvolvimento da API foram realizados diversos testes com o objetivo de validar o correto funcionamento das principais funcionalidades do sistema.

Os testes incidiram sobre a comunicação entre os diferentes componentes da arquitetura, verificando a correta troca de informação entre a API, a base de dados PostgreSQL e o Elasticsearch. Foram também efetuadas validações ao comportamento dos principais endpoints, garantindo que os pedidos eram processados corretamente e que as respostas apresentavam o formato esperado.

Para a implementação dos testes unitários foi utilizada a biblioteca *Mockito*, permitindo simular o comportamento das dependências dos diferentes componentes da aplicação. Desta forma, foi possível testar isoladamente controladores e serviços, verificando tanto os cenários de sucesso como as situações de erro, sem necessidade de recorrer às dependências reais.

Além disso, foram realizados testes de integração para confirmar o funcionamento conjunto dos diferentes serviços, assegurando a consistência dos dados e a fiabilidade do sistema.

A realização destes testes contribuiu para identificar e corrigir problemas durante o desenvolvimento, aumentando a estabilidade e a robustez da aplicação antes da sua disponibilização.

3.3 Elasticsearch

O Elasticsearch é o componente responsável pela indexação e pesquisa dos metadados recolhidos dos repositórios universitários. Embora toda a informação seja armazenada de

forma persistente na base de dados PostgreSQL, as pesquisas realizadas pelos utilizadores são efetuadas sobre índices mantidos no Elasticsearch.

Esta separação permite tirar partido das características específicas de cada tecnologia. O PostgreSQL é utilizado como fonte principal dos dados, garantindo a sua persistência, integridade e consistência através de um modelo relacional. Por sua vez, o Elasticsearch é responsável por disponibilizar pesquisas rápidas e eficientes sobre os documentos indexados, permitindo responder a consultas complexas em poucos milissegundos.

Após a recolha dos metadados pelo *web crawler*, a informação é armazenada no PostgreSQL. Posteriormente, um processo de sincronização copia os documentos para o Elasticsearch, onde são analisados e indexados. A API comunica diretamente com o Elasticsearch para executar as pesquisas, devolvendo ao utilizador os resultados ordenados pela sua relevância.

Embora o PostgreSQL disponibilize funcionalidades de pesquisa textual através do mecanismo *Full-Text Search*, esta solução foi considerada insuficiente para os objetivos do projeto. O sistema pretende evoluir para suportar um número crescente de documentos provenientes de várias universidades, bem como pesquisas mais avançadas e mecanismos de ordenação por relevância.

Já o Elasticsearch foi concebido especificamente para funcionar como um motor de pesquisa, disponibilizando um conjunto de funcionalidades mais avançadas e um melhor desempenho em cenários com grandes volumes de informação.

Embora o PostgreSQL fosse suficiente para a versão inicial do projeto, a utilização do Elasticsearch oferece uma solução mais preparada para futuras evoluções. À medida que forem adicionadas novas universidades e o número de dissertações aumentar, será possível manter tempos de resposta reduzidos.

3.3.1 Motivação para a utilização do Elasticsearch

Uma das decisões arquiteturais mais relevantes do projeto foi a utilização do Elasticsearch como motor de pesquisa dedicado. Embora fosse possível realizar pesquisas diretamente sobre a base de dados PostgreSQL, esta abordagem apresenta limitações quando o volume de dados aumenta e quando são necessárias funcionalidades avançadas de pesquisa textual.

O Elasticsearch foi escolhido pelas seguintes razões:

- **Pesquisa Full-Text:** permite pesquisar palavras e expressões em títulos, resumos e outros campos textuais de forma muito mais eficiente do que consultas SQL tradicionais.
- **Ordenação por relevância:** os resultados são classificados automaticamente de acordo com a sua proximidade ao termo pesquisado, apresentando primeiro os documentos mais relevantes.
- **Elevado desempenho:** foi concebido especificamente para operações de pesquisa e indexação, conseguindo responder rapidamente mesmo com centenas de milhares de documentos indexados.
- **Escalabilidade:** suporta crescimento horizontal através da distribuição dos índices por múltiplos nós, permitindo acomodar um aumento significativo do volume de informação.

- **Suporte para filtros:** possibilita combinar pesquisas textuais com filtros por universidade, autor, ano de publicação ou categoria sem degradação significativa do desempenho.

Foram consideradas outras alternativas, nomeadamente a utilização exclusiva do PostgreSQL ou de motores de pesquisa como Apache Solr. No entanto, o Elasticsearch apresentou uma melhor integração com o ecossistema Spring Boot através do módulo Spring Data Elasticsearch, além de disponibilizar uma API moderna e uma configuração relativamente simples para o contexto deste projeto.

3.3.2 Modelo de Indexação

Cada dissertação é representada no Elasticsearch através de um documento contendo os metadados mais relevantes para pesquisa.

A estrutura simplificada de um documento indexado é apresentada de seguida:

```
{
  "id": "...",
  "title": "Título da dissertação",
  "abstract": "Resumo da dissertação",
  "year": 2026,
  "url": "https://...",
  "authors": "...",
  "subjects": "...",
  "type": "...",
  "language": "por",
  "fileUrl": "https://...",
  "university": "Instituto Superior de Engenharia de Lisboa",
  "hash": "..."
}
```

Os campos `title` e `abstract` constituem os principais elementos utilizados durante as pesquisas, sendo analisados e indexados pelo Elasticsearch para permitir pesquisas textuais eficientes.

3.3.3 Processo de Indexação

O processo de indexação inicia-se após a recolha dos metadados pelo *web crawler*. Os documentos obtidos são armazenados na base de dados PostgreSQL e posteriormente sincronizados com o Elasticsearch.

A Figura 2 ilustra este fluxo de informação.

O processo pode ser resumido da seguinte forma:

1. O *web crawler* recolhe os metadados dos repositórios universitários.
2. Os dados são armazenados na base de dados PostgreSQL.
3. O backend converte os registos armazenados em documentos de pesquisa.
4. Os documentos são indexados no Elasticsearch.

5. As pesquisas efetuadas pelos utilizadores são executadas sobre os índices criados.

Esta abordagem permite manter uma separação clara entre armazenamento persistente e otimização de pesquisa.

3.3.4 Funcionamento das Pesquisas

Quando um utilizador submete uma pesquisa através da interface web, o pedido é encaminhado para a API desenvolvida em Spring Boot. O backend comunica com o Elasticsearch e executa uma pesquisa sobre os campos indexados.

A pesquisa é realizada utilizando consultas *multi-match*, permitindo procurar simultaneamente em vários campos do documento, nomeadamente o título e o resumo da dissertação.

Após a execução da consulta, o Elasticsearch devolve os documentos ordenados por relevância. O backend transforma estes resultados em objetos de resposta e envia-os para o frontend, onde são apresentados ao utilizador.

3.3.5 Vantagens para o Projeto

A utilização do Elasticsearch permite que o sistema se aproxime do comportamento de um motor de pesquisa especializado, oferecendo uma experiência mais rápida e eficiente aos utilizadores.

Entre os principais benefícios destacam-se:

- Redução do tempo de resposta das pesquisas;
- Melhor relevância dos resultados apresentados;
- Capacidade de suportar grandes volumes de dissertações;
- Facilidade de implementação de novos filtros;
- Possibilidade de adicionar funcionalidades avançadas no futuro, como pesquisa aproximada (*fuzzy search*), sugestões automáticas e autocompletação.

Desta forma, o Elasticsearch constitui um elemento fundamental da arquitetura do Unidoc Finder, garantindo um mecanismo de pesquisa eficiente e escalável para a consulta de dissertações académicas provenientes de múltiplos repositórios universitários.

3.4 Base de Dados

A base de dados é responsável pelo armazenamento permanente da informação recolhida pelos repositórios universitários. Para este projeto foi escolhido o PostgreSQL, uma vez que oferece fiabilidade, facilidade de integração com o Spring Boot e suporte para relações entre entidades.

Embora as pesquisas sejam efetuadas através do Elasticsearch, todos os dados são inicialmente armazenados na base de dados. Desta forma, o PostgreSQL funciona como fonte principal de informação, enquanto o Elasticsearch é utilizado apenas para otimizar as pesquisas.

3.4.1 Modelo de Dados

A versão atual do sistema utiliza duas entidades principais:

- **University** – representa uma universidade e o respetivo repositório institucional.
- **Thesis** – representa uma tese ou dissertação indexada pelo sistema.

Cada universidade pode possuir várias teses associadas, existindo assim uma relação do tipo um-para-muitos entre as duas entidades.

3.4.2 Estrutura das Tabelas

A tabela `university` armazena o nome da instituição e o endereço do respetivo repositório.

A tabela `thesis` armazena informação sobre cada dissertação, incluindo o título, resumo, ano de publicação e ligação para o documento original.

3.4.3 Fluxo de Dados

O processo de armazenamento funciona da seguinte forma:

1. O *web crawler* recolhe os metadados dos repositórios universitários.
2. Os dados são guardados no PostgreSQL.
3. O Elasticsearch indexa a informação armazenada.
4. As pesquisas realizadas pelos utilizadores são efetuadas sobre os índices do Elasticsearch.

Esta abordagem permite combinar a fiabilidade de uma base de dados relacional com a rapidez de um motor de pesquisa especializado.

3.5 Web Crawler

O componente de recolha foi implementado como uma aplicação em JavaScript/Node.js. A execução principal encontra-se no ficheiro `index.js`, que coordena o processo de recolha, filtragem, deduplicação e envio dos dados para a API. A recolha HTTP das respostas OAI-PMH é realizada através do ficheiro `fetcher.js`, a interpretação dos metadados é feita em `parser.js`, e o ficheiro `repositories.js` obtém da API os repositórios que devem ser consultados.

A implementação segue uma abordagem de *harvesting* através de OAI-PMH. Esta escolha reduz a dependência da estrutura visual de cada página HTML, porque os repositórios expõem os seus registos através de respostas XML normalizadas. Para cada repositório é construída uma chamada `ListRecords`. Nos endpoints cujo endereço termina em `/openaire4` é utilizado o `metadataPrefix=oai_openaire`; nos restantes é utilizado o `metadataPrefix=oai_dc`. Quando a resposta contém um `resumptionToken`, o crawler usa esse token para obter a página seguinte de resultados, repetindo o processo até deixar de existir um novo token.

Nota: O crawler contém múltiplos valores destinados a debugging que podem ser alterados através de variáveis de ambiente. Portanto nesta subsecção a “execução normal” refere-se à execução do crawler sem qualquer valor de configuração alterado.

3.5.1 Repositórios configurados

O ficheiro `repositories.js` obtém dinamicamente os repositórios através de um pedido GET ao endpoint `http://localhost:8080/api/universities`. Para cada repositório, a API fornece o identificador da instituição, o seu nome e o endereço do respetivo endpoint OAI-PMH, através dos campos `id`, `name` e `repoUrl`. A lista devolvida pela API é exportada através da constante `REPOSITORIES` e percorrida pelo crawler.

3.5.2 Recolha HTTP

O ficheiro `fetcher.js` contém a função `fetchText`, responsável por descarregar as respostas XML dos endpoints OAI-PMH. Esta função define o *User-Agent* e envia o cabeçalho `Accept` com preferência por conteúdos XML. Durante a execução normal, cada pedido possui um tempo limite de 30000 ms. Quando ocorre uma falha, são realizadas até duas tentativas adicionais, com pausas de 1000 ms e 2000 ms, respetivamente. Caso todas as tentativas falhem, a função devolve um valor nulo e o processamento do repositório atual é terminado. Entre páginas consecutivas do mesmo repositório é também aplicada uma pausa de 250 ms, reduzindo a frequência dos pedidos enviados aos servidores.

3.5.3 Metadados extraídos

A extração dos metadados é feita a partir de elementos identificados pelos nomes locais utilizados pelo Dublin Core, como `title`, `creator`, `description` e `subject`. Os registos marcados como removidos são ignorados e, para cada registo válido, são extraídos os campos relevantes para a pesquisa e apresentação dos resultados.

Um registo OAI-PMH em Dublin Core contém elementos do seguinte tipo:

```
<record>
  <header>
    <identifier>oai:repositorio.exemplo.pt:123456789/10</identifier>
    <datestamp>2026-05-01</datestamp>
  </header>
  <metadata>
    <oai_dc:dc>
      <dc:title>Título da dissertação</dc:title>
      <dc:creator>Nome do autor</dc:creator>
      <dc:date>2026</dc:date>
      <dc:description>Resumo do trabalho académico</dc:description>
      <dc:subject>Web Crawler</dc:subject>
      <dc:type>masterThesis</dc:type>
      <dc:language>por</dc:language>
      <dc:identifier>https://repositorio.exemplo.pt/handle/...</dc:identifier>
    </oai_dc:dc>
  </metadata>
</record>
```

A estrutura interna construída pelo crawler contém os seguintes campos:

- `repository`: identificador do repositório;
- `university`: nome da instituição;

- **title:** título do documento;
- **authors:** lista de autores;
- **description:** resumo ou descrição;
- **year:** ano de publicação, extraído dos campos de data ou, quando necessário, dos identificadores;
- **subjects:** palavras-chave ou áreas temáticas;
- **type:** lista de tipos de documento declarados pelo repositório;
- **language:** idioma do documento;
- **url:** ligação para a página pública do registo no repositório;
- **fileUrl:** ligação direta para o PDF, quando existe;
- **oaiIdentifier:** identificador OAI-PMH do registo;
- **datestamp:** data de atualização indicada pelo repositório.
- **hash:** hash SHA-1 utilizado na identificação e deduplicação do documento.

Durante esta fase também é feita limpeza textual: remoção de marcas XML/HTML, decodificação de entidades XML, normalização de espaços e eliminação de valores vazios. O objetivo é transformar a resposta XML original num objeto mais simples e adequado para indexação.

3.5.4 Filtragem de teses e dissertações

Nem todos os registos expostos por um repositório correspondem a teses ou dissertações. Por esse motivo, o crawler aplica uma função de classificação simples, `isThesis`, que procura termos característicos no título, resumo, tipo, assuntos, URL, PDF e identificador OAI-PMH.

O padrão de deteção inclui expressões como `masterthesis` e `doctoralthesis`. Esta abordagem permite abranger repositórios que usam valores normalizados, como `info:eu-repo/semantics/masterThesis`, e também repositórios que usam descrições textuais menos uniformes.

3.5.5 Deduplicação

A deduplicação local dos documentos é realizada durante o processo de crawling, antes do envio de cada registo para a API. Para cada documento, o crawler constrói uma chave de identificação, dando prioridade ao URL da página do documento, ao URL direto do ficheiro PDF e ao identificador OAI-PMH. Caso estes campos não estejam disponíveis, é usada uma combinação do título, autores e ano. A chave obtida é convertida num hash SHA-1 e comparada com um conjunto de hashes processados durante a execução atual. Se o hash já existir, o documento é ignorado; caso contrário, é registado como novo e pode prosseguir para o envio. Esta primeira verificação evita o processamento repetido de registos com a mesma chave durante uma recolha.

3.5.6 Envio dos dados para a API

Durante a execução normal, os documentos aceitos pelo processo de filtragem e deduplicação são enviados individualmente para o endpoint `http://localhost:8080/api/thesis`. Antes de realizar o envio, o crawler efetua um pedido `GET` ao endpoint `/api/thesis/exists`, fornecendo o hash do documento através do parâmetro `hash`. Se a API indicar que esse hash já existe, o pedido de criação não é realizado. Quando o documento ainda não existe, é enviado um pedido `POST` com conteúdo JSON. O corpo do pedido contém os campos `title`, `abstract`, `year`, `url`, `authors`, `subjects`, `type`, `language`, `fileUrl`, `universityId` e `hash`. A descrição recolhida é limitada a um máximo de 2000 caracteres e enviada no campo `abstract`. Os diferentes valores de tipo são unidos numa única cadeia de texto, e o identificador do repositório é enviado como `universityId`. Os campos `oaiIdentifier` e `datestamp` são utilizados internamente durante o processamento, mas não são incluídos no pedido de criação enviado para a API.

Após a conclusão do processo de recolha e envio dos documentos, o crawler desencadeia automaticamente um pedido `POST` para o endpoint `/api/search/sync`. Esta operação inicia a sincronização entre a base de dados PostgreSQL[5] e o índice Elasticsearch, garantindo que os documentos adicionados durante a execução do crawler ficam disponíveis para pesquisa.

3.5.7 Testes

Foram desenvolvidos testes unitários para validar o funcionamento dos principais componentes do crawler. Estes testes foram implementados com recurso à framework *Mocha* e permitem verificar que as diferentes funcionalidades produzem os resultados esperados em condições normais e em situações de erro.

Os testes abrangem os módulos responsáveis pela comunicação com os repositórios OAI-PMH, pela extração e processamento dos metadados, pela identificação de teses e dissertações e pelos mecanismos de deduplicação. Foram igualmente considerados diferentes cenários de entrada, de forma a garantir que o crawler consegue lidar corretamente com respostas válidas, dados incompletos e erros durante o processo de recolha.

A existência destes testes facilita a deteção de problemas durante o desenvolvimento e contribui para garantir a estabilidade do crawler sempre que são introduzidas alterações na implementação.

3.5.8 Limitações da implementação atual

A implementação atual privilegia a simplicidade, mas apresenta algumas limitações. Em primeiro lugar, o crawler recolhe apenas metadados disponibilizados por OAI-PMH, não extraindo o texto integral dos PDFs. Isto significa que a pesquisa incide sobretudo sobre título, autores, resumo, assuntos e restantes campos Dublin Core[10].

Em segundo lugar, a identificação de teses e dissertações depende de padrões textuais. Embora estes padrões cubram os casos mais comuns, podem existir registos mal classificados pelo repositório ou documentos cujo tipo esteja descrito de forma inesperada. Nesses casos, alguns documentos relevantes podem não ser incluídos ou alguns documentos menos relevantes podem passar o filtro.

Por fim, a interpretação XML é feita por expressões regulares simples. Esta solução é suficiente para respostas OAI-PMH previsíveis, mas uma implementação mais robusta poderia utilizar uma biblioteca XML dedicada, especialmente se fosse necessário suportar

metadados com estruturas mais complexas ou namespaces menos consistentes.

4 Conclusão

Este capítulo resume o trabalho desenvolvido no âmbito do projeto Unidoc Finder, os principais resultados alcançados, os desafios encontrados durante a implementação e as melhorias que poderão ser realizadas em versões futuras.

Foi possível construir uma base funcional para uma plataforma de pesquisa de dissertações, composta por vários componentes integrados entre si. O sistema desenvolvido permite demonstrar a viabilidade da solução proposta, especialmente no que diz respeito à recolha, organização, indexação e pesquisa de metadados provenientes de repositórios académicos portugueses.

4.1 Tarefas Cumpridas

Foi implementada uma aplicação web em React e TypeScript, permitindo ao utilizador introduzir termos de pesquisa, visualizar resultados e aplicar filtros sobre os documentos apresentados. A interface foi organizada em componentes reutilizáveis, facilitando a manutenção e evolução futura da aplicação.

Foi desenvolvida uma API em Kotlin com Spring Boot, responsável pela comunicação entre o frontend, a base de dados PostgreSQL e o Elasticsearch. Esta API disponibiliza endpoints para pesquisa, registo de dissertações, registo de universidades, sincronização com o motor de pesquisa, obtenção das universidades registadas e verificação da existência de documentos identificados por um digest. Desta forma, foi criada uma separação clara entre a interface do utilizador, a lógica da aplicação e os mecanismos de armazenamento e pesquisa.

Ao nível do armazenamento, foi configurada uma base de dados PostgreSQL para guardar de forma persistente informação sobre universidades e dissertações. Em paralelo, foi integrado o Elasticsearch como motor de pesquisa textual, permitindo indexar os metadados recolhidos e apresentar resultados ordenados por relevância.

Outro componente essencial desenvolvido foi o web crawler, responsável pela recolha automática de metadados a partir de diferentes repositórios institucionais. Este componente utiliza o protocolo OAI-PMH para obter registos em formato Dublin Core, extraíndo informação como título, autor, resumo, ano, tipo de documento, idioma, palavras-chave e ligações para os documentos originais. Foram ainda implementados mecanismos de filtragem e de deduplicação.

Por fim, os diferentes componentes da aplicação foram preparados para execução com Docker, o que simplifica a configuração do ambiente de desenvolvimento e facilita a integração entre frontend, backend, base de dados, Elasticsearch.

4.2 Desafios

O maior desafio encontrado ao longo do projeto esteve relacionado com a recolha de dados a partir de diferentes repositórios académicos. Embora vários repositórios disponibilizem metadados através de OAI-PMH, a forma como esses dados são preenchidos nem sempre é uniforme. Campos como o tipo de documento, o resumo, os autores, as palavras-chave ou o ano de publicação podem variar bastante entre instituições, tanto no formato como na qualidade da informação disponibilizada.

Esta falta de uniformização dificultou a criação de um processo de extração completamente consistente. Alguns repositórios utilizam valores normalizados para identificar teses e dissertações, enquanto outros recorrem a descrições textuais menos previsíveis.

Como consequência, foi necessário implementar uma lógica de classificação baseada em padrões textuais, capaz de reconhecer termos associados a dissertações e teses. No entanto, esta abordagem não é perfeita e pode originar falsos positivos ou excluir documentos relevantes quando os metadados estão incompletos ou mal classificados.

Outro desafio importante foi lidar com a diversidade dos próprios repositórios. Cada instituição pode expor coleções, identificadores, ligações e filtros de forma diferente, o que torna difícil criar um crawler totalmente genérico. Mesmo recorrendo ao OAI-PMH, continuaram a existir diferenças na estrutura dos registos, na disponibilidade de campos e na existência ou não de ligações diretas para os ficheiros PDF.

A deduplicação dos documentos também representou uma dificuldade relevante. O mesmo documento pode aparecer com URL diferentes, identificadores distintos ou pequenas variações no título e nos autores. Para minimizar este problema, foi criada uma chave estável baseada em vários campos, mas a eliminação completa de duplicados exigiria uma estratégia mais avançada de comparação semântica.

Ao nível da pesquisa, o desafio passou por garantir que os resultados apresentados fossem relevantes para o utilizador. A configuração do Elasticsearch, a escolha dos campos indexados e a ponderação entre título, resumo, autores, assuntos e universidade são fatores que influenciam diretamente a qualidade dos resultados.

4.3 Trabalho Futuro

Embora os objetivos inicialmente definidos tenham sido alcançados, existem diversas funcionalidades que poderão ser desenvolvidas futuramente para aumentar a qualidade e utilidade da plataforma.

Uma das principais evoluções passa pelo alargamento do número de repositórios suportados, permitindo disponibilizar um conjunto ainda mais abrangente de dissertações e teses produzidas em instituições portuguesas. Em simultâneo, poderá ser melhorado o processo de interpretação dos ficheiros XML através da utilização de bibliotecas mais especializadas, aumentando a robustez da extração dos metadados.

Ao nível da pesquisa, será igualmente vantajoso implementar filtros avançados diretamente no backend e no Elasticsearch, permitindo realizar pesquisas mais precisas.

Outra melhoria relevante consiste na introdução de mecanismos de paginação mais completos, incluindo informação sobre o número total de resultados e páginas disponíveis, proporcionando uma experiência de utilização mais intuitiva.

Por fim, poderão ser exploradas funcionalidades adicionais do Elasticsearch, como pesquisa aproximada, autocompletação, sugestões de pesquisa, expansão de sinónimos, melhor normalização linguística e técnicas de otimização da relevância dos resultados.

Em conclusão, o Unidoc Finder permitiu demonstrar a viabilidade de uma plataforma centralizada para pesquisa de dissertações e teses académicas em Portugal. O trabalho desenvolvido resultou numa solução funcional que integra recolha automática de dados, armazenamento estruturado, indexação eficiente e uma interface moderna para pesquisa e consulta de documentos. Apesar das melhorias que poderão ser implementadas futuramente, o projeto cumpre os objetivos inicialmente propostos e estabelece uma base sólida para a evolução de uma ferramenta que poderá contribuir para facilitar o acesso à produção científica das instituições de ensino superior portuguesas.

Referências

- [1] Patel, J. M. (2021). *Getting structured data from the internet: Running web crawlers/scrapers on a big data production scale*. Apress.
- [2] React. Disponível em: <https://react.dev>. Acedido a: 07/03/2026.
- [3] Kotlin Lang - <https://kotlinlang.org>. Acedido a: 07/03/2026.
- [4] Spring Boot - <https://spring.io/projects/spring-boot>. Acedido a: 07/03/2026.
- [5] Postgres - <https://www.postgresql.org/docs/current/index.html>. Acedido a: 16/04/2026
- [6] Elasticsearch - <https://www.elastic.co/docs>. Acedido a: 07/03/2026.
- [7] Gupta, M. (2019). *Mastering Elasticsearch 7.x: Build modern, fast, and scalable search applications*. Packt Publishing.
- [8] Open Archives Initiative Protocol for Metadata Harvesting - <https://www.openarchives.org/pmh/>. Acedido a 26/04/2026.
- [9] DSpace - <https://wiki.lyrasis.org/spaces/DSPACE/pages/68067273/Documentation>. Acedido a 11/07/2026
- [10] Dublin Core - <https://www.openarchives.org/OAI/openarchivesprotocol.html#dublincore>. Acedido a 26/04/2026.